

FICHA TÉCNICA

Projeto de Análise de Dados

Análise de Hipóteses com Dados do Spotify 2023.

Objetivo: O objetivo desse projeto é validar hipóteses relacionadas a características das músicas, comportamento em playlists e popularidade em diferentes plataformas, utilizando correlação e gráficos de dispersão para entender fatores que influenciam o sucesso em streams.

Equipe: Thayna Moreira e Carolina Sousa.

Ferramentas e Tecnologias: Google Sheets, BigQuery, Power BI e Google Slides.

Processamento e Análises:

1. Importação dos Dados:

Antes de importar os dados para o BigQuery, visualizamos os arquivos no Google Sheets para entendermos a estrutura. Após isso, conectamos três tabelas principais no BigQuery:

- track_in_spotify (dados do desempenho no Spotify)
- track_in_competition (desempenho em outras plataformas, como Deezer e Shazam)
- track_technical_info (características técnicas das faixas)

2. Tratamento dos Dados: Na track_in_spotify, não encontramos nulos. Na track_in_competition, substituí 50 nulos da coluna in_shazam_charts por -1, indicando ausência nas paradas. Na track_technical_info, substituí 95 nulos da coluna key por “sem informação”.

Foram identificadas 4 faixas duplicadas na track_in_spotify. Mantive apenas as versões com maior número de streams.

As outras duas tabelas não apresentaram duplicatas.

Exclusão de variáveis irrelevantes: Removemos as colunas key e mode da tabela track_technical_info por não agregarem valor à análise.

Limpeza de dados categóricos: Usei a função REGEXP_REPLACE para remover caracteres especiais das colunas track_name e artists_name. Renomeei colunas com % para evitar erros futuros.

3. Criação de Variáveis: Criamos uma nova variável chamada data_full, unindo as colunas de ano, mês e dia em um único campo de data, facilitando análises temporais

4. Criação de Nova Tabela Consolidada: Criamos a tabela spotify_completo, unindo as três tabelas com base na coluna id... Criei também a tabela total_playlist, agrupando os dados para obter o total de playlists por música.

5. Análise Exploratória: Fiz algumas matrizes e tabelas para analisar as variáveis categóricas e responder perguntas exploratórias, como:

1. Qual é o Número de Músicas por Artista e Ano?
2. Qual o total de Streams por Artista?
3. Quais são as Características Médias por Artista?
4. Número de Músicas por Mês de Lançamento
5. Total de Streams por Artista com Participação em Playlists.

Calculamos média, mediana e moda para analisar o comportamento geral das faixas em relação a streams, popularidade e desempenho em outras plataformas.

Criamos histogramas para observar como variáveis como streams e total de playlists estão distribuídas, o que ajudou a identificar tendências e concentrações.

Aplicamos o cálculo do desvio padrão nessas variáveis para avaliar a dispersão dos dados em relação à média. Criamos visualizações no Power BI para analisar a evolução de variáveis ao longo do tempo, destacando padrões de comportamento e variações temporais.

Calculamos os quartis das variáveis danceability, speechiness, liveness, instrumentalness, acousticness, energy e valence para entender melhor a distribuição dessas características técnicas das músicas. A partir dos valores obtidos, criamos as categorias:

Alta (valores acima do 3º quartil)

Média Alta (entre o 2º e 3º quartil)

Média Baixa (entre o 1º e 2º quartil)

Baixa (valores abaixo do 1º quartil)

6. Técnica de Análise: Hipóteses Validadas e Resultados.

Validamos as 5 hipóteses com uso de gráficos de dispersão e correlações:

1. Músicas com BPM mais alto fazem mais sucesso. | Correlação: -0.0021 | Resultado: Falso.
2. Músicas populares no Spotify também são populares no Deezer. | Correlação: 0.6002 | Resultado: Verdadeira.
3. Músicas com mais playlists têm mais streams .| Correlação: -0.7843 | Resultado: Verdadeira.
4. Artistas com mais músicas têm mais streams .| Correlação: -0.7791 | Resultado: Verdadeira.
5. Características técnicas influenciam streams .| Correlação: < 0.12 | Resultado: Parcialmente verdadeira.

7. Dashboard final: Criei um dashboard no Power BI com os seguintes elementos: Scorecards com métricas gerais (total de músicas, total de artistas, total de streams, média de playlists)

Gráficos de dispersão para cada hipótese testada, com linhas de tendência

Filtros por ano de lançamento, artista e músicas com mais energy.

Resultado e Conclusões: A análise mostrou que o sucesso de uma música não está relacionado ao BPM ou características técnicas isoladas, mas sim a fatores como: Número de playlists em que está inserida. Produtividade do artista (mais faixas lançadas = mais streams). Popularidade consistente entre plataformas (Spotify e Deezer)

Além disso, a validação das hipóteses com correlação e gráficos facilitou a identificação de padrões e insights relevantes para estratégias musicais e de marketing.

Limitações/Próximos Passos: Algumas colunas com valores nulos exigiram decisões de preenchimento que podem ser refinadas com mais dados.

A categorização das características foi feita isoladamente — agora, o próximo passo é analisar múltiplas variáveis juntas para entender o impacto combinado delas nas músicas.

Também pretendo testar dashboards mais interativos com Looker Studio para tornar a visualização mais dinâmica.